

Khai thác các mẫu hiếm (Rare Pattern Mining)

Bài tập lớn môn Khai thác dữ liệu nâng cao

[Họ tên sinh viên — MSSV]

Tháng 6 năm 2026

Nội dung trình bày

- Bài toán & động cơ
- Ba định nghĩa mẫu hiếm
- Ba thuật toán: **AprioriRare**, **AprioriInverse**, **CORI**
- Độ đo tương quan & tính null-invariance
- Cài đặt, kiểm chứng tự động, thực nghiệm UCI Mushroom

Động cơ: mẫu hiếm nhưng giá trị cao

- Y tế: tổ hợp triệu chứng bệnh hiếm $\Rightarrow$ giá trị chẩn đoán cao
- Công nghiệp: lỗi sản phẩm hiếm gặp = đối tượng cần phát hiện
- An ninh mạng: bất thường = hiếm theo định nghĩa
- FIM truyền thống bỏ qua hoàn toàn các mẫu này

Vấn đề: hạ minsup là không đủ

- Giải pháp ngây thơ: hạ thấp *minsup*
- Hệ quả 1: **bùng nổ tổ hợp** số itemset
- Hệ quả 2: nhiều — nhiều “mẫu hiếm” có $sup = 0$ (không tồn tại!)
- Cần: định nghĩa chặt chẽ + thuật toán riêng + độ đo lọc mẫu giả

Ví dụ

Giao dịch	Các mục
T1	pasta, lemon, bread, orange
T2	pasta, lemon
T3	pasta, orange, cake
T4	pasta, lemon, orange, cake

- $minsup = 2 \Rightarrow$ **11** itemset phổ biến
- $\{\text{bread}\}: sup = 1$ • $\{\text{bread, cake}\}: sup = 0$
- Dùng để chạy tay & kiểm chứng cài đặt

Ba định nghĩa mẫu hiếm

- **Infrequent:** $\sup(X) < \minsup$ — bùng nổ, chứa cả $\sup = 0$

Ba định nghĩa mẫu hiếm

- **Infrequent:** $sup(X) < minsup$ — bùng nổ, chứa cả $sup = 0$
- **Minimal rare (mRI):** hiếm, mọi tập con đều phổ biến
⇒ biên dưới của vùng hiếm trong dàn itemset

Ba định nghĩa mẫu hiếm

- **Infrequent:** $\sup(X) < \minsup$ — bùng nổ, chứa cả $\sup = 0$
- **Minimal rare (mRI):** hiếm, mọi tập con đều phổ biến
 $\Rightarrow$ biên dưới của vùng hiếm trong dàn itemset
- **Perfectly rare (PRI):** $\minsup \leq \sup < \maxsup$,
mọi item thành phần đều hiếm

Ba định nghĩa mẫu hiếm

- **Infrequent:** $\text{sup}(X) < \text{minsup}$ — bùng nổ, chứa cả $\text{sup} = 0$
- **Minimal rare (mRI):** hiếm, mọi tập con đều phổ biến
 $\Rightarrow$ biên dưới của vùng hiếm trong dàn itemset
- **Perfectly rare (PRI):** $\text{minsup} \leq \text{sup} < \text{maxsup}$,
mọi item thành phần đều hiếm
- Ví dụ ($\text{minsup} = 2$): mRI = {bread}, {lemon, cake} • PRI = {bread}

AprioriRare: tìm biên hiếm tối thiểu

- Duyệt theo mức (level-wise) như Apriori
- Ứng viên sống sót qua prune mà không phổ biến $\Rightarrow$ **chính là mRI**
- Itemset hiếm không dùng sinh ứng viên tiếp
- Ví dụ: mRI = **{bread}, {lemon, cake}** khớp bài giảng
- Nhược: phải duyệt toàn bộ vùng phổ biến

AprioriInverse: thu hẹp ngay từ đầu

- Hai ngưỡng ($minsup$, $maxsup$)
- **Loại mọi item phổ biến ngay bước khởi tạo**
- Đúng đắn: mọi item hiếm $\Rightarrow$ mọi tập con hiếm (điều kiện PRI tự thỏa)
- **Đổi lại: bỏ sót mẫu lai {item hiếm + item phổ biến}**
- Ví dụ (1.1, 3.1): 5 PRI khớp bài giảng

Mẫu giả: phổ biến $\neq$ đáng tin

- {pasta, cake} xuất hiện ở **50%** giao dịch
- Nhưng pasta có mặt trong **mọi** giao dịch
- Đồng xuất hiện là tất yếu — **không có liên hệ thật** (spurious)
- Cần độ đo tương quan để lọc

Hai độ đo: bond và all-confidence

- $bond(X) = \frac{sup(X)}{dsup(X)}$ — tỉ lệ giao dịch “liên quan” chứa toàn bộ X
- $bond = 1$: các mục **luôn** đi cùng nhau
- $allconf(X) = \frac{sup(X)}{\max_{i \in X} sup(\{i\})}$ — confidence **nhỏ nhất** của mọi luật từ X
- Cả hai: $= 1$ với itemset đơn; **anti-monotone** $\Rightarrow$ cắt tỉa kiểu Apriori
- Ví dụ: $bond(\{cake, bread\}) = 0$ • $bond(\{pasta, orange\}) = 3/4$

Null-invariance: vì sao lift thất bại

- Null transaction: giao dịch không chứa mục nào của mẫu
- χ^2 , lift bị **bóp méo** bởi hàng triệu giao dịch không liên quan
- bond, all-confidence, cosine, Kulczynski: **null-invariant**
- Mẫu hiếm $\subset$ phần rất nhỏ dữ liệu $\Rightarrow$ **bắt buộc** dùng null-invariant


CORI: hiếm + tương quan trong một lần duyệt

- Rare correlated: $sup(X) < maxsup$ **và** $bond(X) \geq minbond$
- Hai ràng buộc đối ngẫu: hiếm = **monotone** • bond = **anti-monotone**
- Duyệt kiểu Eclat, mỗi itemset giữ **TID-List + DTID-List**
- bond rớt ngưỡng $\Rightarrow$ cắt cả nhánh; $sup \geq maxsup \Rightarrow$ chưa xuất nhưng vẫn mở rộng
- Ví dụ (3, 0.6): **{bread}, {cake}, {orange, cake}** khớp bài giảng

Cài đặt & kiểm chứng 100%




- Python 3.13, **chỉ thư viện chuẩn**; TID-set dùng chung cho cả 3 thuật toán
- **19 assert** đối chiếu từng con số kỳ vọng trên ví dụ — **100% ĐẠT**
- Phủ FIM, AprioriRare, AprioriInverse, CORI & các độ đo
- {pasta, cake}: $lift = 1.0$, $bond = 0.5 \Rightarrow$ xác nhận mẫu giả bằng số

Exp A — Cái giá của việc đi xuyên vùng phổ biến



- UCI Mushroom: 8 124 giao dịch, 118 item (dữ liệu dày)
- $minsup$ 0.6 $\rightarrow$ 0.2: #frequent tăng $\sim 890\times$ (51 $\rightarrow$ 45 391); #mRI chỉ $\sim 8\times$ (122 $\rightarrow$ 986)

Exp B & C — PRI rẻ, CORI giàu ngữ nghĩa



- AprioriInverse: **mili-giây** — alphabet hiếm rất nhỏ (bài toán khác, không phải benchmark cùng điều kiện)
- CORI: bảo hòa 90–104 mẫu khi nới *minbond* 0.95 → 0.5; mẫu *bond* = 1.0: {odor=m, ...}, *sup* = 36 (0.44%)

Kết luận: ba đánh đổi

- **mRI gọn nhưng đắt** — phải duyệt toàn vùng phổ biến
- **PRI rẻ nhưng hẹp** — bỏ sót mẫu lai
- **CORI cân bằng** — ràng buộc kép, kết quả nhỏ & giàu ngữ nghĩa
- Hướng 2021–2026: metaheuristic (MRI-CE), fuzzy, utility, **privacy**

Cảm ơn & Hỏi đáp

Xin cảm ơn thầy/cô và các bạn!

3 định nghĩa • 3 thuật toán • kiểm chứng 100% • UCI
Mushroom

Mã nguồn & kết quả: `advantage_data_mining/code, results/`

Mời thầy/cô và các bạn đặt câu hỏi